

## Métodos Numéricos - Clase 6

Ulises Bussi- Javier Portillo

1° cuatrimestre 2020

## Introducción Ajustes de curvas

## Regresión Lineal

### Cuadrados Mínimos

#### Ejemplo

#### Coeficiente de determinación

## Linealización y ajuste

## Ajuste Polinomial

## Interpolación Polinómica

### Interpolación de Newton

# Ajustes de Curvas

## Introducción Ajustes de curvas

### Regresión Lineal

#### Cuadrados Mínimos

#### Ejemplo

#### Coeficiente de determinación

### Linealización y ajuste

### Ajuste Polinomial

### Interpolación Polinómica

#### Interpolación de Newton

# Modelado y Datos experimentales.

**Predecir comportamiento** Dado un conjunto de datos, predecir nuevos valores.

**¿Por qué?** Es imposible medir todos los posibles valores de un modelo físico → Modelamos y predecimos.

# Modelado y Datos experimentales.

**Predecir comportamiento** Dado un conjunto de datos, predecir nuevos valores.

**¿Por qué?** Es imposible medir todos los posibles valores de un modelo físico → Modelamos y predecimos.

# Modelado y Datos experimentales.

**Predecir comportamiento** Dado un conjunto de datos, predecir nuevos valores.

**¿Por qué?** Es imposible medir todos los posibles valores de un modelo físico → Modelamos y predecimos.

# Ajustes de Curvas

Introducción Ajustes de curvas

**Regresión Lineal**

**Cuadrados Mínimos**

Ejemplo

Coeficiente de determinación

Linealización y ajuste

Ajuste Polinomial

Interpolación Polinómica

Interpolación de Newton


# Regresión Lineal

Dado un conjunto de pares ordenados  $\rightarrow$  Encontrar la recta que mejor los representa.




# Regresión Lineal

Dado un conjunto de pares ordenados → Encontrar la recta que mejor los representa.




# Regresión Lineal

Dado un conjunto de pares ordenados → Encontrar la recta que mejor los representa.




# Regresión Lineal

Dado un conjunto de pares ordenados → Encontrar la recta que mejor los representa.



# Regresión Lineal

Dado un conjunto de pares ordenados  $\rightarrow$  Encontrar la recta que mejor los representa.



**Hay que definir un criterio**

# Regresión Lineal

Podemos usar el Residual:

Dado  $\{x_i, y_i\}$ ,  $i = 1, 2, \dots, 3$  y la recta  $\hat{y} = ax + b$  el residual  $S$  se calcula cómo:

$$S = \sum_{i=1}^n y_i - \hat{y}_i = \sum_{i=1}^n y_i - (a * x_i + b)$$

E intentar minimizarlo  $\rightarrow$  Encontrar  $\{a, b\}$  para que el " error " sea lo más pequeño posible ( $S$  cercano a cero).

**No es buena idea!**

# Regresión Lineal

Podemos usar el Residual:

Dado  $\{x_i, y_i\}$ ,  $i = 1, 2, \dots, 3$  y la recta  $\hat{y} = ax + b$  el residual  $S$  se calcula cómo:

$$S = \sum_{i=1}^n y_i - \hat{y}_i = \sum_{i=1}^n y_i - (a * x_i + b)$$

E intentar minimizarlo  $\rightarrow$  Encontrar  $\{a, b\}$  para que el " error " sea lo más pequeño posible ( $S$  cercano a cero).

No es buena idea!

# Regresión Lineal

Podemos usar el Residual:

Dado  $\{x_i, y_i\}$ ,  $i = 1, 2, \dots, 3$  y la recta  $\hat{y} = ax + b$  el residual  $S$  se calcula cómo:

$$S = \sum_{i=1}^n y_i - \hat{y}_i = \sum_{i=1}^n y_i - (a * x_i + b)$$

Intentar minimizarlo  $\rightarrow$  Encontrar  $\{a, b\}$  para que el "error" sea lo más pequeño posible ( $S$  cercano a cero).

No es buena idea!

# Regresión Lineal

Podemos usar el Residual:

Dado  $\{x_i, y_i\}$ ,  $i = 1, 2, \dots, 3$  y la recta  $\hat{y} = ax + b$  el residual  $S$  se calcula cómo:


$$S = \sum_{i=1}^n y_i - \hat{y}_i = \sum_{i=1}^n y_i - (a * x_i + b)$$

E intentar minimizarlo  $\rightarrow$  Encontrar  $\{a, b\}$  para que el "error" sea lo más pequeño posible ( $S$  cercano a cero).

**No es buena idea!**



# Regresión Lineal



Para la recta  $y_1$ :

$$S = (2 - 2 \cdot 1) + (4 - 2 \cdot 2) = 0$$

Para la recta  $y_2$ :

$$S = (2 - 3) + (4 - 3) = 0$$

# Cuadrados Mínimos

**Propuesta:** minimizar

$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n [y_i - (a * x_i + b)]^2$$

O sea, encontrar  $a$  y  $b$  que hagan a  $S$  lo más chico posible.

¿**Cómo?** Busco donde:

$$\frac{\partial S}{\partial b} = 0 \leftarrow \text{valor de } b \text{ que minimiza } S$$

$$\frac{\partial S}{\partial a} = 0 \leftarrow \text{valor de } a \text{ que minimiza } S$$

# Cuadrados Mínimos

**Propuesta:** minimizar

$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n [y_i - (a * x_i + b)]^2$$

O sea, encontrar  $a$  y  $b$  que hagan a  $S$  lo más chico posible.

¿Cómo? Busco donde:

$$\frac{\partial S}{\partial b} = 0 \leftarrow \text{valor de } b \text{ que minimiza } S$$

$$\frac{\partial S}{\partial a} = 0 \leftarrow \text{valor de } a \text{ que minimiza } S$$

# Cuadrados Mínimos

**Propuesta:** minimizar

$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n [y_i - (a * x_i + b)]^2$$

O sea, encontrar  $a$  y  $b$  que hagan a  $S$  lo más chico posible.

**¿Cómo?** Busco donde:

$$\frac{\partial S}{\partial b} = 0 \leftarrow \text{valor de } b \text{ que minimiza } S$$

$$\frac{\partial S}{\partial a} = 0 \leftarrow \text{valor de } a \text{ que minimiza } S$$

# Cuadrados Mínimos

$$\frac{\partial S}{\partial b} = \frac{\partial \sum_{i=1}^n [y_i - (a * x_i + b)]^2}{\partial b}$$

$$\frac{\partial S}{\partial b} = -2 \sum_{i=1}^n [y_i - (a * x_i + b)] = 0$$

$$\sum_{i=1}^n y_i - \sum_{i=1}^n (a * x_i) - \sum_{i=1}^n b = 0$$

$$nb + \left[ \sum_{i=1}^n x_i \right] a = \left[ \sum_{i=1}^n y_i \right]$$

$$\frac{\partial S}{\partial a} = \frac{\partial \sum_{i=1}^n [y_i - (a * x_i + b)]^2}{\partial a}$$

$$\frac{\partial S}{\partial a} = -2 \sum_{i=1}^n [(y_i - (a * x_i + b))(x_i)] = 0$$

$$\sum_{i=1}^n x_i * y_i - \sum_{i=1}^n a * x_i^2 - \sum_{i=1}^n x_i * b = 0$$

$$\left[ \sum_{i=1}^n x_i \right] b + \left[ \sum_{i=1}^n x_i^2 \right] a = \left[ \sum_{i=1}^n x_i * y_i \right]$$

# Cuadrados mínimos


Ahora tenemos este sistema de 2 ecuaciones con 2 incógnitas que se puede resolver:

$$a = \frac{n \sum (x_i * y_i) - \sum x_i * \sum y_i}{n * \sum x_i^2 - (\sum x_i)^2}$$

$$b = \bar{y} - a * \bar{x}$$

# Ejemplo: cuadrados mínimos

Dado  $x = [1, 2, 3, 4, 5, 6, 7]$  e  $y = [3,93, 4,58, 8,25, 9,36, 8,94, 14,89, 15,61]$  encontrar la recta que mejor ajusta por cuadrados mínimos.




Calculemos valores que necesitamos:

$$\begin{aligned}\sum x_i &= 28 & \sum y_i &= 65,56 \\ \sum x_i * y_i &= 318,59 & \sum x_i^2 &= 140 \\ \bar{x} = \frac{\sum x_i}{n} &= 4 & \bar{y} = \frac{\sum y_i}{n} &= 9,37\end{aligned}$$

# Ejemplo: cuadrados mínimos

Dado  $x = [1, 2, 3, 4, 5, 6, 7]$  e  $y = [3,93, 4,58, 8,25, 9,36, 8,94, 14,89, 15,61]$  encontrar la recta que mejor ajusta por cuadrados mínimos.




Calculemos valores que necesitamos:

$$\begin{aligned} \sum x_i &= 28 & \sum y_i &= 65,56 \\ \sum x_i * y_i &= 318,59 & \sum x_i^2 &= 140 \\ \bar{x} = \frac{\sum x_i}{n} &= 4 & \bar{y} = \frac{\sum y_i}{n} &= 9,37 \end{aligned}$$



Dado  $x = [1, 2, 3, 4, 5, 6, 7]$  e  $y = [3,93, 4,58, 8,25, 9,36, 8,94, 14,89, 15,61]$  encontrar la recta que mejor ajusta por cuadrados mínimos.




$$a = \frac{7 * 318,59 - 28 * 65,56}{7 * 140 - 28^2} = 2,0125$$

$$b = 9,37 - 2,0125 * 4 = 1,32$$

$$\hat{y} = 2,0125x + 1,32$$

Dado  $x = [1, 2, 3, 4, 5, 6, 7]$  e  $y = [3,93, 4,58, 8,25, 9,36, 8,94, 14,89, 15,61]$  encontrar la recta que mejor ajusta por cuadrados mínimos.




$$a = \frac{7 * 318,59 - 28 * 65,56}{7 * 140 - 28^2} = 2,0125$$

$$b = 9,37 - 2,0125 * 4 = 1,32$$

$$\hat{y} = 2,0125x + 1,32$$

Dado  $x = [1, 2, 3, 4, 5, 6, 7]$  e  $y = [3,93, 4,58, 8,25, 9,36, 8,94, 14,89, 15,61]$  encontrar la recta que mejor ajusta por cuadrados mínimos.



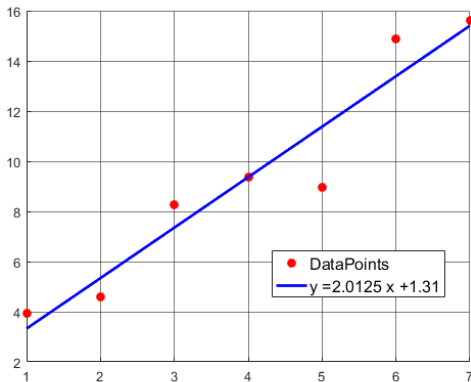
$$a = \frac{7 * 318,59 - 28 * 65,56}{7 * 140 - 28^2} = 2,0125$$

$$b = 9,37 - 2,0125 * 4 = 1,32$$

$$\hat{y} = 2,0125x + 1,32$$

## Ejemplo: cuadrados mínimos

Dado  $x = [1, 2, 3, 4, 5, 6, 7]$  e  $y = [3,93, 4,58, 8,25, 9,36, 8,94, 14,89, 15,61]$  encontrar la recta que mejor ajusta por cuadrados mínimos.





# Coefficiente de Determinación.

Una vez realizado el ajuste podemos calcular:

El cuadrado de residual para todos los puntos: Y el residual respecto de la media:

$$S_r = \sum_{i=1}^n (y_i - a * x_i - b)^2$$

$$S_t = \sum_{i=1}^n (y_i - \bar{y})^2$$



# Coeficiente de Determinación.

Se llama coeficiente de determinación a la variable  $r \in [0, 1]$  que se calcula cómo:

$$r^2 = \frac{S_t - S_r}{S_t}$$

Nos dice cuanto mejor es ajustar la recta a los datos que simplemente usar el promedio.

# Coefficiente de Determinación.

Se llama coeficiente de determinación a la variable  $r \in [0, 1]$  que se calcula cómo:

$$r^2 = \frac{S_t - S_r}{S_t}$$

Nos dice cuanto mejor es ajustar la recta a los datos que simplemente usar el promedio.

# Ajustes de Curvas

Introducción Ajustes de curvas

Regresión Lineal

Cuadrados Mínimos

Ejemplo

Coeficiente de determinación

Linealización y ajuste

Ajuste Polinomial

Interpolación Polinómica

Interpolación de Newton



# Relaciones no lineales.

Muchas veces, nos encontramos con relaciones No Lineales:

$$y = a * e^{b*x}$$

Modelo  
Exponencial

$$y = a * x^b$$

Modelo de  
potencia

$$y = a * \frac{x}{x + b}$$

Modelo de  
crecimiento  
con saturación

Es posible encontrar una transformación tal que se pueda expresar como un modelo lineal!

# Relaciones no lineales.

Muchas veces, nos encontramos con relaciones No Lineales:

$$y = a * e^{b*x}$$

**Modelo  
Exponencial**

$$y = a * x^b$$

Modelo de  
potencia

$$y = a * \frac{x}{x + b}$$

Modelo de  
crecimiento  
con saturación

Es posible encontrar una transformación tal que se pueda expresar como un modelo lineal!

# Relaciones no lineales.

Muchas veces, nos encontramos con relaciones No Lineales:

$$y = a * e^{b*x}$$

Modelo  
Exponencial

$$y = a * x^b$$

Modelo de  
potencia

$$y = a * \frac{x}{x + b}$$

Modelo de  
crecimiento  
con saturación

Es posible encontrar una transformación tal que se pueda expresar como un modelo lineal!

# Relaciones no lineales.

Muchas veces, nos encontramos con relaciones No Lineales:

$$y = a * e^{b*x}$$

Modelo  
Exponencial

$$y = a * x^b$$

Modelo de  
potencia

$$y = a * \frac{x}{x + b}$$

Modelo de  
crecimiento  
con saturación

Es posible encontrar una transformación tal que se pueda expresar como un modelo lineal!

# Relaciones no lineales.

Muchas veces, nos encontramos con relaciones No Lineales:

$$y = a * e^{b*x}$$

Modelo  
Exponencial

$$y = a * x^b$$

Modelo de  
potencia

$$y = a * \frac{x}{x + b}$$

Modelo de  
crecimiento  
con saturación

Es posible encontrar una transformación tal que se pueda expresar como un modelo lineal!


# Linealización y ajuste

Tomemos el modelo exponencial. Si trabajamos con el  $\ln y$ :

$$\underbrace{\ln y}_{y^*} = \ln(a * e^{b*x})$$

$$y^* = \ln(a) + \ln(e^{b*x})$$

$$y^* = \ln(a) + b * x$$





# Linealización y ajuste

Tomemos el modelo exponencial. Si trabajamos con el  $\ln y$ :

$$\underbrace{\ln y}_{y^*} = \ln(a * e^{b*x})$$

$$y^* = \ln(a) + \ln(e^{b*x})$$

$$y^* = \ln(a) + b * x$$



# Linealización y ajuste


Tomemos el modelo de potencia. Si trabajamos con el  $\ln y$ :

$$\underbrace{\ln y}_{y^*} = \ln(a * x^b)$$

$$y^* = \ln(a) + \ln(x^b)$$

$$y^* = \ln(a) + b * \underbrace{\ln(x)}_{x^*}$$

$$y^* = \ln(a) + bx^*$$





# Linealización y ajuste



Tomemos el modelo de potencia. Si trabajamos con el  $\ln y$ :

$$\underbrace{\ln y}_{y^*} = \ln(a * x^b)$$

$$y^* = \ln(a) + \ln(x^b)$$

$$y^* = \ln(a) + b * \underbrace{\ln(x)}_{x^*}$$

$$y^* = \ln(a) + bx^*$$



# Ajustes de Curvas

Introducción Ajustes de curvas

Regresión Lineal

Cuadrados Mínimos

Ejemplo

Coeficiente de determinación

Linealización y ajuste

Ajuste Polinomial

Interpolación Polinómica

Interpolación de Newton

# Ajuste Polinomial

¿Que sucede si quisieramos ajustar por ejemplo un polinomio de grado 2?

El mismo procedimiento de cuadrados mínimos podría ajustarse con un polinomio de la forma:

$$f(x) = a_0 + a_1x + a_2x^2$$

A la hora de plantear el residual tendríamos:

$$S = \sum_{i=1}^n (y_i - a_0 - a_1 * x_i - a_2x_i^2)^2$$

# Ajuste Polinomial

¿Que sucede si quisieramos ajustar por ejemplo un polinomio de grado 2?

El mismo procedimiento de cuadrados mínimos podría ajustarse con un polinomio de la forma:

$$f(x) = a_0 + a_1x + a_2x^2$$

A la hora de plantear el residual tendríamos:

$$S = \sum_{i=1}^n (y_i - a_0 - a_1 * x_i - a_2x_i^2)^2$$

# Ajuste Polinomial

Debemos ahora derivar respecto a los 3 coeficientes para minimizar:

$$\frac{\partial S}{\partial a_0} = -2 \sum_{i=1}^n (y_i + a_0 + a_1 x_i + a_2 x_i^2)$$

$$\frac{\partial S}{\partial a_1} = -2 \sum_{i=1}^n [(y_i + a_0 + a_1 x_i + a_2 x_i^2) x_i]$$

$$\frac{\partial S}{\partial a_2} = -2 \sum_{i=1}^n [(y_i + a_0 + a_1 x_i + a_2 x_i^2) x_i^2]$$

# Ajuste Polinomial

Operando y despejando como se realizó antes:

$$n * a_0 + a_1 * \sum x_i + a_2 * \sum x_i^2 = \sum y_i$$

$$a_0 * \sum x_i + a_1 * \sum x_i^2 + a_2 * \sum x_i^3 = \sum y_i * x_i$$

$$a_0 * \sum x_i^2 + a_1 * \sum x_i^3 + a_2 * \sum x_i^4 = \sum y_i * x_i^2$$

Un sistema de 3 ecuaciones con 3 incógnitas!!!

# Ajuste Polinomial

Operando y despejando como se realizó antes:

$$n * a_0 + a_1 * \sum x_i + a_2 * \sum x_i^2 = \sum y_i$$

$$a_0 * \sum x_i + a_1 * \sum x_i^2 + a_2 * \sum x_i^3 = \sum y_i * x_i$$

$$a_0 * \sum x_i^2 + a_1 * \sum x_i^3 + a_2 * \sum x_i^4 = \sum y_i * x_i^2$$

**Un sistema de 3 ecuaciones con 3 incógnitas!!!**

# Ajuste Polinomial

En general, este método puede aplicarse a:

- sistemas con varias variables:

$$S = \sum_{i=1}^n z_i - a_0 - a_1 * x_i - a_2 * y_i$$

- sistemas no lineales:  $S = \sum_{i=1}^n y_i - f(x_i)$

En el último caso hay que tener cuidado, el problema puede convertirse en un sistema de ecuaciones no lineal.



# Ajuste Polinomial

En general, este método puede aplicarse a:

- sistemas con varias variables:

$$S = \sum_{i=1}^n z_i - a_0 - a_1 * x_i - a_2 * y_i$$

- sistemas no lineales:  $S = \sum_{i=1}^n y_i - f(x_i)$

En el último caso hay que tener cuidado, el problema puede convertirse en un sistema de ecuaciones no lineal.

# Ajustes de Curvas

Introducción Ajustes de curvas

Regresión Lineal

Cuadrados Mínimos

Ejemplo

Coeficiente de determinación

Linealización y ajuste

Ajuste Polinomial

Interpolación Polinómica

Interpolación de Newton

# Interpolación Polinómica

En general, si queremos predecir valores intermedios a valores dados, proponemos interpolar.

Aproximar el valor utilizando los valores conocidos.

Para un conjunto de  $n$  puntos existe un único polinomio de orden  $n - 1$  que pase por todos esos puntos.

# Interpolación Polinómica

En general, si queremos predecir valores intermedios a valores dados, proponemos interpolar.

Aproximar el valor utilizando los valores conocidos.

Para un conjunto de  $n$  puntos existe un único polinomio de orden  $n - 1$  que pase por todos esos puntos.

# Interpolación Polinómica

En general, si queremos predecir valores intermedios a valores dados, proponemos interpolar.

Aproximar el valor utilizando los valores conocidos.

Para un conjunto de  $n$  puntos existe un único polinomio de orden  $n - 1$  que pase por todos esos puntos.

# Interpolación Polinómica

Supongamos que tenemos 3 puntos conocidos  $(x_i, y_i)$ .

Si queremos ajustar una parábola tenemos que buscar los 3 coeficientes  $a_0, a_1, a_2$  que cumplen

$$a_0 + a_1 * x_i + a_2 * x_i^2 = y_i, \forall i \in [1, 2, 3]$$

Es posible llevar esto a la forma matricial:

$$\begin{bmatrix} x_1^2 & x_1 & 1 \\ x_2^2 & x_2 & 1 \\ x_3^2 & x_3 & 1 \end{bmatrix} \begin{bmatrix} a_2 \\ a_1 \\ a_0 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$$

Esta matriz  $A$  se conoce como matriz de Vandermonde. y son conocidas por ser muy mal condicionadas. → El sistema será muy sensible.

Se puede usar esta solución pero no es aconsejable

# Interpolación Polinómica

Supongamos que tenemos 3 puntos conocidos  $(x_i, y_i)$ .

Si queremos ajustar una parábola tenemos que buscar los 3 coeficientes  $a_0, a_1, a_2$  que cumplen

$$a_0 + a_1 * x_i + a_2 * x_i^2 = y_i, \forall i \in [1, 2, 3]$$

Es posible llevar esto a la forma matricial:

$$\begin{bmatrix} x_1^2 & x_1 & 1 \\ x_2^2 & x_2 & 1 \\ x_3^2 & x_3 & 1 \end{bmatrix} \begin{bmatrix} a_2 \\ a_1 \\ a_0 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$$

Esta matriz  $A$  se conoce como matriz de Vandermonde. y son conocidas por ser muy mal condicionadas. → El sistema será muy sensible.

Se puede usar esta solución pero no es aconsejable

# Interpolación Polinómica

Supongamos que tenemos 3 puntos conocidos  $(x_i, y_i)$ .

Si queremos ajustar una parábola tenemos que buscar los 3 coeficientes  $a_0, a_1, a_2$  que cumplen

$$a_0 + a_1 * x_i + a_2 * x_i^2 = y_i, \forall i \in [1, 2, 3]$$

Es posible llevar esto a la forma matricial:

$$\begin{bmatrix} x_1^2 & x_1 & 1 \\ x_2^2 & x_2 & 1 \\ x_3^2 & x_3 & 1 \end{bmatrix} \begin{bmatrix} a_2 \\ a_1 \\ a_0 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$$

Esta matriz  $A$  se conoce como matriz de Vandermonde. y son conocidas por ser muy mal condicionadas. → El sistema será muy sensible.

Se puede usar esta solución pero no es aconsejable



# Interpolación Polinómica

Supongamos que tenemos 3 puntos conocidos  $(x_i, y_i)$ .

Si queremos ajustar una parábola tenemos que buscar los 3 coeficientes  $a_0, a_1, a_2$  que cumplen

$$a_0 + a_1 * x_i + a_2 * x_i^2 = y_i, \forall i \in [1, 2, 3]$$

Es posible llevar esto a la forma matricial:

$$\begin{bmatrix} x_1^2 & x_1 & 1 \\ x_2^2 & x_2 & 1 \\ x_3^2 & x_3 & 1 \end{bmatrix} \begin{bmatrix} a_2 \\ a_1 \\ a_0 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$$


Esta matriz  $A$  se conoce como matriz de Vandermonde. y son conocidas por ser muy mal condicionadas. → El sistema será muy sensible.

Se puede usar esta solución pero no es aconsejable

# Interpolación de Newton

Si queremos interpolar utilizando 2 puntos, los unimos con una recta y buscamos el valor que nos interesa relacionando las pendientes:

$$\frac{f(x) - y_1}{x - x_1} = \frac{y_2 - y_1}{x_2 - x_1}$$



# Interpolación de Newton


Si queremos interpolar utilizando 2 puntos, los unimos con una recta y buscamos el valor que nos interesa relacionando las pendientes:

$$\frac{f(x) - y_1}{x - x_1} = \frac{y_2 - y_1}{x_2 - x_1}$$

Despejando:

$$f(x) = y_1 + \frac{y_2 - y_1}{x_2 - x_1}(x - x_1)$$

Polinomio interpolador de Newton de grado 1



# Interpolación de Newton

Si queremos interpolar utilizando 3 puntos proponemos el polinomio de grado 3:

$$f(x) = b_0 + b_1(x - x_1) + b_2(x - x_1)(x - x_2)$$

Si reemplazamos por los puntos conocidos tendremos:

$$f(x_1) = b_0 + b_1 \underbrace{(x_1 - x_1)}_0 + b_2 \underbrace{(x_1 - x_1)(x_1 - x_2)}_0 = b_0$$

Con lo que  $b_0 = f(x_1) = y_1$

# Interpolación de Newton

Si queremos interpolar utilizando 3 puntos proponemos el polinomio de grado 3:

$$f(x) = b_0 + b_1(x - x_1) + b_2(x - x_1)(x - x_2)$$

Si reemplazamos por los puntos conocidos tendremos:

$$f(x_1) = b_0 + b_1 \underbrace{(x_1 - x_1)}_0 + b_2 \underbrace{(x_1 - x_1)}_0 (x_1 - x_2) = b_0$$

Con lo que  $b_0 = f(x_1) = y_1$

# Interpolación de Newton

Si queremos interpolar utilizando 3 puntos proponemos el polinomio de grado 3:

$$f(x) = b_0 + b_1(x - x_1) + b_2(x - x_1)(x - x_2)$$

Si reemplazamos por los puntos conocidos tendremos:

$$f(x_2) = b_0 + b_1(x_2 - x_1) + b_2(x_2 - x_1) \underbrace{(x_2 - x_2)}_0$$

con lo que si a  $f(x_2)$  le restamos  $b_0$  y dividimos por  $(x_2 - x_1)$ :

$$b_1 = \frac{f(x_2) - y_1}{x_2 - x_1} = \frac{y_2 - y_1}{x_2 - x_1}$$

# Interpolación de Newton

Si queremos interpolar utilizando 3 puntos proponemos el polinomio de grado 3:

$$f(x) = b_0 + b_1(x - x_1) + b_2(x - x_1)(x - x_2)$$

Si reemplazamos por los puntos conocidos tendremos:

$$f(x_2) = b_0 + b_1(x_2 - x_1) + b_2(x_2 - x_1) \underbrace{(x_2 - x_2)}_0$$

con lo que si a  $f(x_2)$  le restamos  $b_0$  y dividimos por  $(x_2 - x_1)$ :

$$b_1 = \frac{f(x_2) - y_1}{x_2 - x_1} = \frac{y_2 - y_1}{x_2 - x_1}$$

# Interpolación de Newton

Si queremos interpolar utilizando 3 puntos proponemos el polinomio de grado 3:

$$f(x) = b_0 + b_1(x - x_1) + b_2(x - x_1)(x - x_2)$$

Si reemplazamos por los puntos conocidos tendremos:

$$f(x_2) = b_0 + b_1(x_2 - x_1) + b_2(x_2 - x_1) \underbrace{(x_2 - x_2)}_0$$

con lo que si a  $f(x_2)$  le restamos  $b_0$  y dividimos por  $(x_2 - x_1)$ :

$$b_1 = \frac{f(x_2) - y_1}{x_2 - x_1} = \frac{y_2 - y_1}{x_2 - x_1}$$



# Interpolación de Newton

Por último:

$$f(x_3) = b_0 + b_1(x_3 - x_1) + b_2(x_3 - x_1)(x_3 - x_2)$$

Restando  $b_0$ , dividiendo por  $(x_3 - x_1)$ :

$$\frac{f(x_3) - b_0}{x_3 - x_1} = b_1 + b_2(x_3 - x_2)$$

Si restamos el valor hallado de  $b_1$  y dividimos por  $(x_3 - x_2)$ :

$$\frac{\frac{f(x_3) - b_0}{x_3 - x_1} - b_1}{x_3 - x_2} = b_2 \quad \rightarrow \quad b_2 = \frac{\frac{y_3 - y_1}{x_3 - x_1} - \frac{y_2 - y_1}{x_2 - x_1}}{x_3 - x_2}$$

# Interpolación de Newton

Por último:

$$f(x_3) = b_0 + b_1(x_3 - x_1) + b_2(x_3 - x_1)(x_3 - x_2)$$

Restando  $b_0$ , dividiendo por  $(x_3 - x_1)$ :

$$\frac{f(x_3) - b_0}{x_3 - x_1} = b_1 + b_2(x_3 - x_2)$$

Si restamos el valor hallado de  $b_1$  y dividimos por  $(x_3 - x_2)$ :

$$\frac{\frac{f(x_3) - b_0}{x_3 - x_1} - b_1}{x_3 - x_2} = b_2 \quad \rightarrow \quad b_2 = \frac{\frac{y_3 - y_1}{x_3 - x_1} - \frac{y_2 - y_1}{x_2 - x_1}}{x_3 - x_2}$$

# Interpolación de Newton

Por último:

$$f(x_3) = b_0 + b_1(x_3 - x_1) + b_2(x_3 - x_1)(x_3 - x_2)$$

Restando  $b_0$ , dividiendo por  $(x_3 - x_1)$ :

$$\frac{f(x_3) - b_0}{x_3 - x_1} = b_1 + b_2(x_3 - x_2)$$

Si restamos el valor hallado de  $b_1$  y dividimos por  $(x_3 - x_2)$ :

$$\frac{\frac{f(x_3) - b_0}{x_3 - x_1} - b_1}{x_3 - x_2} = b_2 \quad \rightarrow \quad b_2 = \frac{\frac{y_3 - y_1}{x_3 - x_1} - \frac{y_2 - y_1}{x_2 - x_1}}{x_3 - x_2}$$

# Interpolación de Newton

Por último:

$$f(x_3) = b_0 + b_1(x_3 - x_1) + b_2(x_3 - x_1)(x_3 - x_2)$$

Restando  $b_0$ , dividiendo por  $(x_3 - x_1)$ :

$$\frac{f(x_3) - b_0}{x_3 - x_1} = b_1 + b_2(x_3 - x_2)$$

Si restamos el valor hallado de  $b_1$  y dividimos por  $(x_3 - x_2)$ :

$$\frac{\frac{f(x_3) - b_0}{x_3 - x_1} - b_1}{x_3 - x_2} = b_2 \quad \rightarrow \quad b_2 = \frac{\frac{y_3 - y_1}{x_3 - x_1} - \frac{y_2 - y_1}{x_2 - x_1}}{x_3 - x_2}$$

# Interpolación de Newton

Resumiendo el de orden 2:

$$f(x) = b_0 + b_1(x - x_1) + b_2(x - x_1)(x - x_2)$$

donde:

$$b_0 = y_1$$

$$b_1 = \frac{y_2 - y_1}{x_2 - x_1}$$

$$b_2 = \frac{\frac{y_3 - y_1}{x_3 - x_1} - \frac{y_2 - y_1}{x_2 - x_1}}{x_3 - x_2}$$